# План обработки данных и выполнения ДЗ 8

hr-teachers · «Движуха в кадрах» · 03 ноября 2026

**Вывод:** предложенное разделение подходит: очистка исходников, отдельная подготовка признаков, затем сравнение моделей. Для рабочего результата нужно сохранить сборку кадровой витрины между очисткой и Dash и исключить обучение преобразований на тестовом годе.

Объём плана: кодовая часть ДЗ8 и необходимая для неё переработка данных. Статья, подключение модели к интерфейсу, SHAP и What-if в этот объём не входят.

## Рекомендуемый путь данных

Четыре исходных Excel
↓
**Предобработка и очистка.ipynb**: нормализованные таблицы педагогов, образования, ПК/ПП и школ
↓
**build_teachers.py**: единая сборка признаков и кадровой витрины
↓
**data/teachers.parquet**: одна строка на id, year

Далее данные используют два независимых потребителя:
**Dash** показывает кадровую аналитику.
**Подготовка.ipynb** определяет признаки и конвейеры преобразований для **HW_8_Тестирование_моделей.ipynb**. Обучение запускается в исследовании моделей, отдельно от приложения.

Имена дополнительных очищенных файлов нужно закрепить до реализации. Например, data/clean/education.parquet, profdev.parquet и schools.parquet; подробную таблицу педагогов можно оставить в data/data_clean.parquet. Это рекомендация, такие выходы сейчас не реализованы. Для модели при необходимости добавляются агрегаты из подробной таблицы с проверкой ключей.

## Что подтверждено сейчас

Проверена ветка Recreating-data-processing, HEAD b65035e. В «Подготовке» 7 ячеек: загрузка, просмотр и переименование полей; готового ML-конвейера нет. Ноутбук ДЗ8 содержит одну пустую ячейку. Семинар содержит примеры моделей и обработки, но его методику нельзя переносить целиком.

Действующие файлы прочитаны без изменения: data_clean.parquet содержит 417 149 строк и 31 поле; teachers.parquet - 52 723 строки и 34 поля, ключ id, year уникален. Это проверка сохранённых файлов, а не доказательство, что новый ноутбук заново воспроизводит их из Excel.

# Что нужно исправить в текущей схеме

## Очистка дополнительных таблиц теряется

В «Предобработке и очистке» сохраняется только df_clean педагогов (ячейка 138, индексы с нуля). Исправленные df_edu, df_pk и df_school остаются в памяти. build_teachers.py читает образование, ПК/ПП и школы заново из исходных Excel. Поэтому изменения очистки этих таблиц не используются дашбордом. Решение: передавать сборщику очищенные таблицы по согласованной схеме.

## Есть конкретная ошибка при исправлении дат

В ячейке 128 будущие годы образования исправляются в столбце «Дата окончания», хотя после переименования рабочее поле называется date_pass. Нужная дата не исправляется; создаётся другой столбец. Исправить имя, затем проверить, что допустимый диапазон соблюдается в date_pass.

## Агрегаты образования могут смотреть в будущее

В ячейке 68 высший уровень образования вычисляется по id сразу за все годы. Так образование, впервые появившееся в 2024, может попасть в признаки 2022. Для прогнозов агрегировать по id, year и учитывать только сведения, доступные в данном срезе. Та же проверка нужна истории ДПО в add_profdev: одной даты окончания курса недостаточно, если сама запись впервые появилась в будущей выгрузке.

## Статистическая очистка тоже может давать утечку

Медианы по образованию сейчас считаются по объединённым годам; даты категории корректируются медианами и IQR внутри каждого года. Для описательных отчётов это можно отдельно обосновать. Для оценки ML границы и статистики не должны оцениваться на 2023. Оставить исходные значения и флаги ошибок, а обучаемые исправления выполнять в ML-конвейере на train. Это относится и к разбиению на фолды при подборе параметров.

## Нельзя передавать подробную таблицу как выборку людей

Повторы id, year в data_clean.parquet ожидаемы: это предметы и параллели. До обучения нужна одна строка на педагога в году. Сначала агрегировать нагрузку, затем выбирать согласованные кадровые поля; проверить противоречия внутри ключа. Простое обучение на всех строках даст больший вес педагогам с большим числом назначений.

## Пример семинара требует адаптации

В семинаре target строится через последний год появления id (ячейка 20): при пропуске 2023 и возвращении в 2024 это даст неверный исход 2022. Использовать присутствие именно в следующем годовом срезе. Винзоризация сделана до split (ячейка 27), а гиперпараметры сравниваются на 2023 (например, ячейки 47 и 52). Для честной оценки переносим статистические шаги внутрь Pipeline и подбираем параметры внутри 2022.

# Этапы подготовки данных

## 1 Зафиксировать контракт и исходную проверку

Сохранить исходники и исторические ноутбуки. Зафиксировать ключи, типы, определения target и правила отбора школ. До изменений записать количества строк, людей, школ и исходов по годам. Рабочая модель ДЗ8 бинарная: target=1 означает отсутствие в следующем срезе системы; переход в другую школу имеет target=0. За 2024 исход неизвестен.

Проверить влияние фильтра школ до расчёта target: исчезновение после фильтрации не должно автоматически выдаваться за установленный уход из всей системы. Если граница системы - только предоставленный справочник, описать это явно; изменение определения согласовать до пересчёта, не менять его молча.

## 2 Завершить Предобработку и очистку

Читать четыре Excel и их годовые листы; согласовать названия и типы полей; исправлять только объяснимые ошибки. Сохранять исходные и очищенные значения, флаги исправлений и отчёт по качеству. После исправления стажа пересчитать производный прочий стаж; category_active считать по согласованным очищенным датам.

Сохранить все четыре очищенные таблицы. Для педагогов сохранить детализацию предметов и параллелей. Для образования и курсов не уничтожать смысл структурных пропусков: заполнение специализации текстом «не указано» не должно затем ошибочно означать наличие переподготовки в проверке notna(). Статистические замены для ML выполнять отдельно от описательной очистки.

**Готовность:** ноутбук проходит Restart and Run All, сохраняет согласованные выходы; при повторном запуске нет зависимости от старых переменных или processed_pedagog_data.csv. Первый проверочный запуск сохраняет результаты только во временную папку.

## 3 Подключить очищенные таблицы к сборщику

Изменить входы build_teachers.py и адаптировать названия полей, сохранив один набор правил агрегации. Сборщик создаёт итоговую teachers.parquet с контрактом Dash, без кодирования категорий и масштабирования значений для ML. Dashboard/data.py продолжает читать только эту витрину.

Сопоставить старый и новый результат: строки, ключи, школы, исходы, значения признаков. Каждое отличие объяснить очисткой или исправленной ошибкой. Затем выполнить существующий pytest и ручную проверку основных фильтров. Действующий parquet заменять после проверки, а не использовать пересборку как тест с перезаписью.

## 4 Завершить Подготовку

Использовать кадровую витрину и, только если нужно, дополнительные агрегаты из очищенных источников. Создать таблицу признаков с id и year для контроля, выделить X и y. Не включать в X target/is_out_next_year, mobility_status, movement_type, сведения о следующем годе и идентификатор человека. Номер школы считать категорией, не численной величиной.

Выход: список признаков с типами, необученные фабрики преобразований и таблица наблюдений. Не сохранять одну заранее закодированную/масштабированную матрицу для всей CV. Если общий код нужен двум ноутбукам, вынести небольшие функции в обычный Python-модуль; не импортировать один ноутбук из другого.

# Эксперименты для ДЗ 8

## 5 Зафиксировать проверку по времени

Внешнее разделение: обучение 2022, тест 2023; 2024 не используется для fit и оценки качества. В текущей витрине: 17 396 наблюдений и 2 596 уходов в 2022; 17 394 и 2 299 в 2023. Постоянный прогноз «не ушёл» даёт на 2023 accuracy около 0,8678 и balanced accuracy 0,5. Пересчитать эти числа на итоговой выборке.

Внутри 2022 использовать StratifiedKFold с фиксированным random_state для подбора параметров и выбора метода масштабирования. Это внутренняя проверка одного среза, она не заменяет внешнюю временную оценку. Все обучаемые преобразования и ресэмплинг выполняются заново внутри каждого обучающего фолда. Повторение того же человека в train 2022 и test 2023 допустимо для задачи прогноза следующего среза; id не подавать в модель.

## 6 Сравнить семь семейств моделей

| Модель | Масштабирование | Небольшая сетка параметров |
|---|---|---|
| KNN | Без; Standard; Robust | n_neighbors: 3, 5, 9, 15; weights: uniform/distance |
| Дерево решений | Без; контрольный Standard | max_depth: 3, 5, 10, None; min_samples_leaf: 1, 10 |
| Логистическая регрессия | Без; Standard; Robust | C: 0.1, 1, 10; контролировать сходимость |
| SVM | Без; Standard; Robust | LinearSVC, C: 0.1, 1, 10; RBF по желанию |
| Random Forest | Без; контрольный Standard | n_estimators: 100, 200; max_depth: 5, None |
| Бустинг | Обычно без | AdaBoost: 50, 100 деревьев; learning_rate: 0.1, 1 |
| Стекинг | Внутри каждой базовой модели | 2-3 базовые модели и логистическая метамодель; OOF на 2022 |

Сетки - стартовые рекомендации, а не обязательный полный перебор всех сочетаний. AdaBoost позволяет выполнить пункт про бустинг без XGBoost. LinearSVC - вариант SVM с меньшей стоимостью; вероятности для обязательных метрик не нужны. Отдельный Bagging над KNN в задании не обязателен.

## 7 Исследовать именно влияние масштаба

Для KNN, LR и SVM сравнить одинаковые признаки, кодирование и фолды при трёх вариантах: без scaler, StandardScaler, RobustScaler. MinMaxScaler можно добавить, если есть гипотеза из распределений. Бинарные и OHE-поля оставить без масштабирования. Не смешивать изменение масштаба с удалением признаков или сменой кодировщика в одном эксперименте.

Фиксировать accuracy и balanced accuracy, среднее и разброс по CV, параметры и время обучения. Основной критерий выбора рекомендую balanced accuracy из-за дисбаланса; это нужно написать до выбора победителя. Графики зависимости от параметров строить по внутренней CV; на 2023 показывать итоговые оценки зафиксированных конфигураций.

# Балансировка и объяснение результата

## 8 Провести сопоставимый эксперимент балансировки

Для выбранного по CV алгоритма сравнить без балансировки, class_weight="balanced" и SMOTE только на train. Сохранить одни признаки, разбиения и критерий подбора. Тест 2023 оставить с естественной долей уходов. Ресэмплинг не применяется при predict и не создаёт строк в кадровой витрине дашборда.

До реализации проверить API победителя: у KNN нет class_weight, у AdaBoost он тоже не задаётся напрямую. Не выдавать weights="distance" за балансировку классов. Если победитель не поддерживает class_weight, показать это ограничение, сравнить для него доступные варианты и дополнительно провести полное тройное сравнение для лучшей модели с поддержкой class_weight. Явно подписать, что это другой алгоритм.

Обычный SMOTE на OHE/бинарных признаках создаёт дробные значения категорий. Для буквального выполнения ДЗ можно оставить такой опыт на числовом представлении, отметив ограничение. Для смешанных признаков добавить SMOTENC: сохранить маску категорий, масштабировать числовые признаки, выполнить ресэмплинг, затем финальное кодирование. SMOTENC - обоснованное дополнение или явно объяснённый вариант SMOTE, его нельзя незаметно подменять в таблице.

## 9 Корректно обучить стекинг

Базовые модели получают отдельные Pipeline; метамодель обучается по out-of-fold прогнозам только 2022 года. Преобразования и балансировка находятся внутри базовых Pipeline, а не один раз перед StackingClassifier. Не обучать метамодель на предсказаниях базовых моделей по их собственному train или на 2023. Начать с простой комбинации KNN, дерева и RF, без большого перебора ансамблей.

## 10 Вывести важности признаков

Для дерева, RF и AdaBoost вывести топ-5 feature_importances_. Для LR и линейной SVM - топ-5 по модулю коэффициента, отдельно показать знак; сравнение размеров коэффициентов требует учёта масштаба. Для KNN и RBF SVM встроенного топ-5 нет: допустимо указать «не применимо», либо дополнительно использовать permutation importance. Коэффициенты метамодели стекинга - это веса базовых моделей, а не важности исходных кадровых признаков.

После OHE сохранять имена полученных признаков. В отчёте разделять значимость конкретной категории и исходного поля. Объяснения связей не выдавать за доказательство причин увольнения.

## 11 Собрать результаты и выводы

Одна строка итоговой таблицы: алгоритм, scaler, балансировка, параметры, CV balanced accuracy, test accuracy, test balanced accuracy, топ-5 признаков. Внутренние CV-метрики и тестовые метрики хранить в разных колонках. Дополнительно полезны recall/precision/F1 класса ухода и confusion matrix; они не заменяют обязательные две метрики.

Ответить комментариями в ноутбуке: кто лучше по выбранному критерию; где масштабирование помогло; что изменили веса и SMOTE; какие признаки важны. Если победитель выбран по результатам просмотра всех тестовых оценок, назвать сравнение исследовательским: 2023 уже не является независимым подтверждением качества выбранного победителя.

# Порядок выполнения и критерии сдачи

| Порядок | Работа | Проверяемый результат |
|---|---|---|
| 1 | Контракт и снимок исходных показателей | Понятны ключи, target, выборка и роли таблиц |
| 2 | Очистка из Excel | Все четыре очищенных выхода; исправлены даты и будущие сведения |
| 3 | Сборщик и Dash | Витрина с прежним контрактом; объяснены изменения; pytest проходит |
| 4 | Подготовка признаков | Одна строка id, year; X/y; фабрики Pipeline без заранее обученной обработки |
| 5 | Модели и масштабирование | Семь семейств; одинаковые фолды; две обязательные метрики |
| 6 | Балансировка и топ-5 | Сопоставимые эксперименты; корректный SMOTE; важности подписаны |
| 7 | Чистый запуск и отчёт | Ноутбук с outputs, таблицей и ответами; воспроизводимый запуск |

## Что сдаём по кодовой части

Основной файл - HW/HW_8_Тестирование_моделей.ipynb с комментариями ко всем этапам, сохранёнными выводами, графиками и сводной таблицей. Ноутбук должен запускаться после Restart and Run All с документированным рабочим каталогом. Если он читает подготовленный файл или общий модуль, приложить их и точную команду подготовки; не полагаться на переменные из другого ноутбука. Подготовка исходников оформляется отдельно, чтобы проверяющий мог воспроизвести вход Д38.

Для рабочих ноутбуков prototype/ сейчас используются пути ../data/. Для HW/ эти пути тоже ведут в data/, а docs/семинар использует ./data/ и требует адаптации. Зафиксировать единый способ поиска корня проекта и проверить запуск с выбранным рабочим каталогом.

## Зависимости и проверки

Действующий requirements.txt покрывает приложение и pytest. Для выполнения Д38 нужно явно описать окружение scikit-learn, scipy, matplotlib, seaborn, Jupyter и imbalanced-learn. Добавлять XGBoost только при выборе именно его, для варианта с AdaBoost он не нужен. При подготовке этого плана модели не обучались, очистка целиком не запускалась, исходные файлы и ноутбуки не изменялись.

После рефакторинга данных выполнить существующий pytest. После изменения ML обязательно повторить 2022 → 2023; все fit, подбор параметров и ресэмплинг ограничить обучающими данными. Сначала собирать в памяти или временном каталоге. Сохранение модели и прогнозы 2024 можно сделать следующим этапом проекта; для кодовой части Д38 они не требуются.

## Основания плана

Локальные материалы: PDF задания «Неделя 8 ... Д3_0110d25e» (кодовая часть); docs/«Неделя 8 ... Семинар.ipynb»; prototype/«Предобработка и очистка.ipynb»; prototype/«Подготовка.ipynb»; prototype/build_teachers.py; dashboard/data.py; dashboard/tests/test_data.py; README.md. Контекст и ограничения: PROJECT_CONTEXT.pdf, AUDIT.pdf и DATA_CATALOG.pdf от 02.11.2026. Они описывают прежний снимок проекта и не подменяют проверку текущих файлов.

Методические источники:
scikit-learn: Common pitfalls - обучение преобразований и утечки;
scikit-learn: StackingClassifier - out-of-fold прогнозы;
imbalanced-learn: Common pitfalls - ресэмплинг только внутри train;
imbalanced-learn: SMOTENC - смешанные категориальные и числовые признаки.