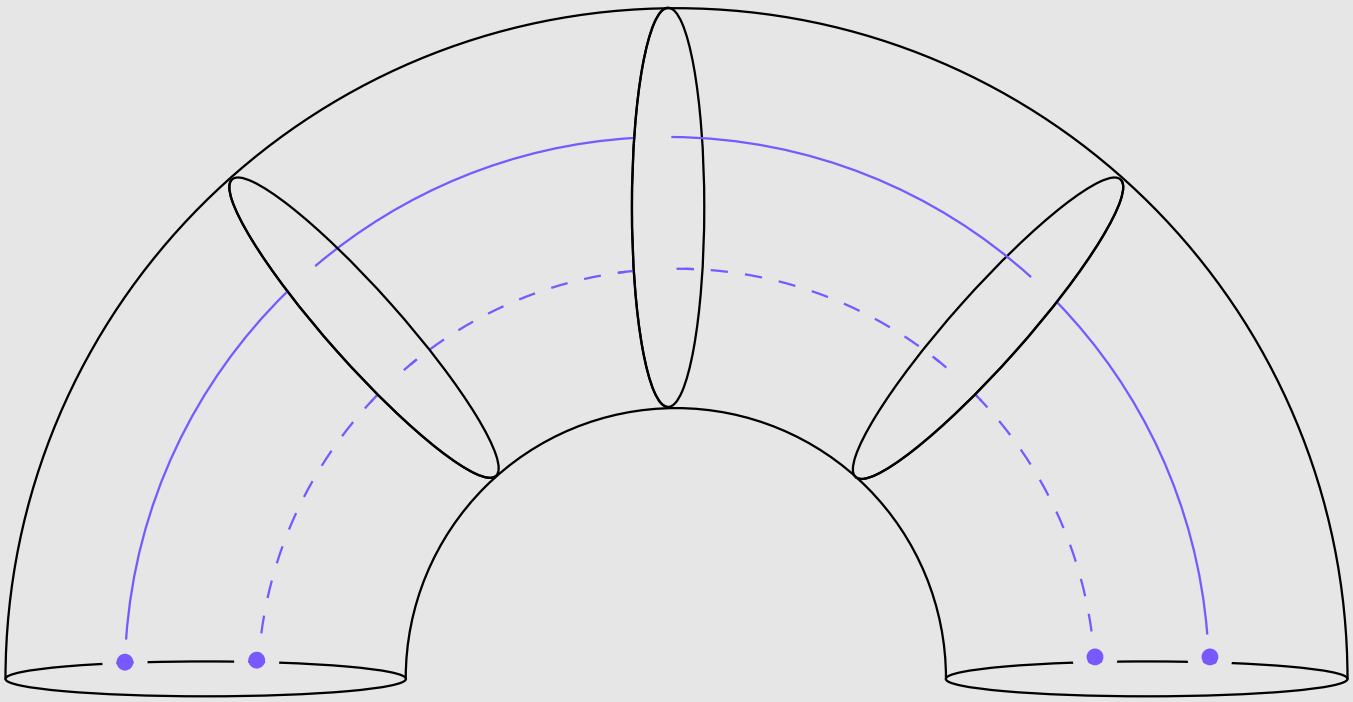
STEM

Домашнее задание

Научная студия. Кадровая динамика

07

Предобработка данных



Домашняя работа. Неделя 7

ЧАСТЬ 1

Тебе нужно подготовить датасет для дальнейшего анализа, приведя их к единому стандарту. Нужно взять общую таблицу, которая ты сделал на предыдущих занятиях.

> Помни про утечку данных!

Обработка категориальных данных

1. Найди все столбцы с текстовыми или категориальными значениями.
2. Проанализируй пропуски в этих столбцах. Обрати внимание, что не все «специальные» значения являются пропусками (иногда это может означать «нет категории», а не отсутствие данных). Обоснуй, как ты трактуешь каждое подозрительное значение.
3. Классифицируй каждый категориальный признак:
   - номинальный (нет порядка),
   - ординальный (есть порядок),
   - бинарный (уже 0/1),
   - идентификатор (ID-подобный).
4. Примени кодирование в соответствии с типом:
   - номинальные с малым числом уровней (*One-Hot Encoding*)
   - номинальные с высокой кардинальностью (*Target Encoding*)
   - ординальные (*Ordinal Encoding*)
   - бинарные оставляй как есть.
5. Обоснуй выбор метода для каждого признака.
6. Удали исходные категориальные столбцы после кодирования.

Масштабирование количественных переменных

1. Для числовых признаков заполни пропуски (при их наличии). Обоснуй стратегию заполнения.
2. Проведи диагностику распределений для каждого числового признака:
   - посчитай *skewness* и *kurtosis*,
   - определи, есть ли выбросы.
3. Выбери метод масштабирования для каждого признака отдельно, исходя из диагностики:
   - симметричное распределение без выбросов — *StandardScaler*,
   - ограниченный известный диапазон — *MinMaxScaler*,
   - выбросы или тяжёлые хвосты — *RobustScaler*,
   - сильная скошенность — логарифмирование, затем масштабирование.
4. Обоснуй выбор метода для каждого признака или группы признаков.

> Помни, что бинарные признаки мы не масштабируем.

Анализ корреляции и отбор признаков

1. Построй матрицу корреляций (тепловую карту) на закодированных и отмасштабированных признаках.

   Примечание: если ты использовал Target Encoding, не включай его в матрицу корреляций.
2. Найди пары признаков с высокой корреляцией ($|corr| > 0.85$).
3. Для каждой пары обоснуй, какой признак удалить (например, хуже интерпретируется, содержит больше пропусков и т.п.).
4. Удали выбранные признаки, чтобы избежать мультиколлинеарности.
5. Визуализируй итоговую матрицу корреляций после очистки.

Формат сдачи

Загрузи Python Notebook в LMS с комментариями к каждому этапу решения.

ЧАСТЬ 2

Тебе нужно подготовить аннотацию и введение твоей статьи.

Аннотация

В аннотации описывается кратко (на 150–200 слов) суть статьи. Аннотация должна быть самодостаточной (понятной без чтения самой статьи), чтобы читатель мог сделать для себя вывод, подходит ли эта статья для него. В аннотации должны быть указаны проблема, цель, методы и результаты исследования.

Введение

Во введении обычно описывается сама идея исследования и контекст, ставится задача исследования.

Здесь нет задачи описать результат исследования. Обычно во введении пишут сам контекст (актуальность), обзор исследований по данной тематике, чего не хватает в текущих исследованиях, цель и задачу статьи и реже структуру статьи (что будет в первой главе, во второй и так далее).

Размер введения обычно составляет 10–20% от предполагаемой статьи.

В статье не указывается содержание, как в курсовых проектах. Если есть потребность кратко описать, о чём будут главы, это надо сделать во введении.

> Примеры аннотации и введения можно посмотреть в статьях, представленных в LMS в разделе «Командное задание: обзор научной статьи».

Формат сдачи

Часть статьи должна быть представлена в формате Word (.doc/.docx) или PDF.