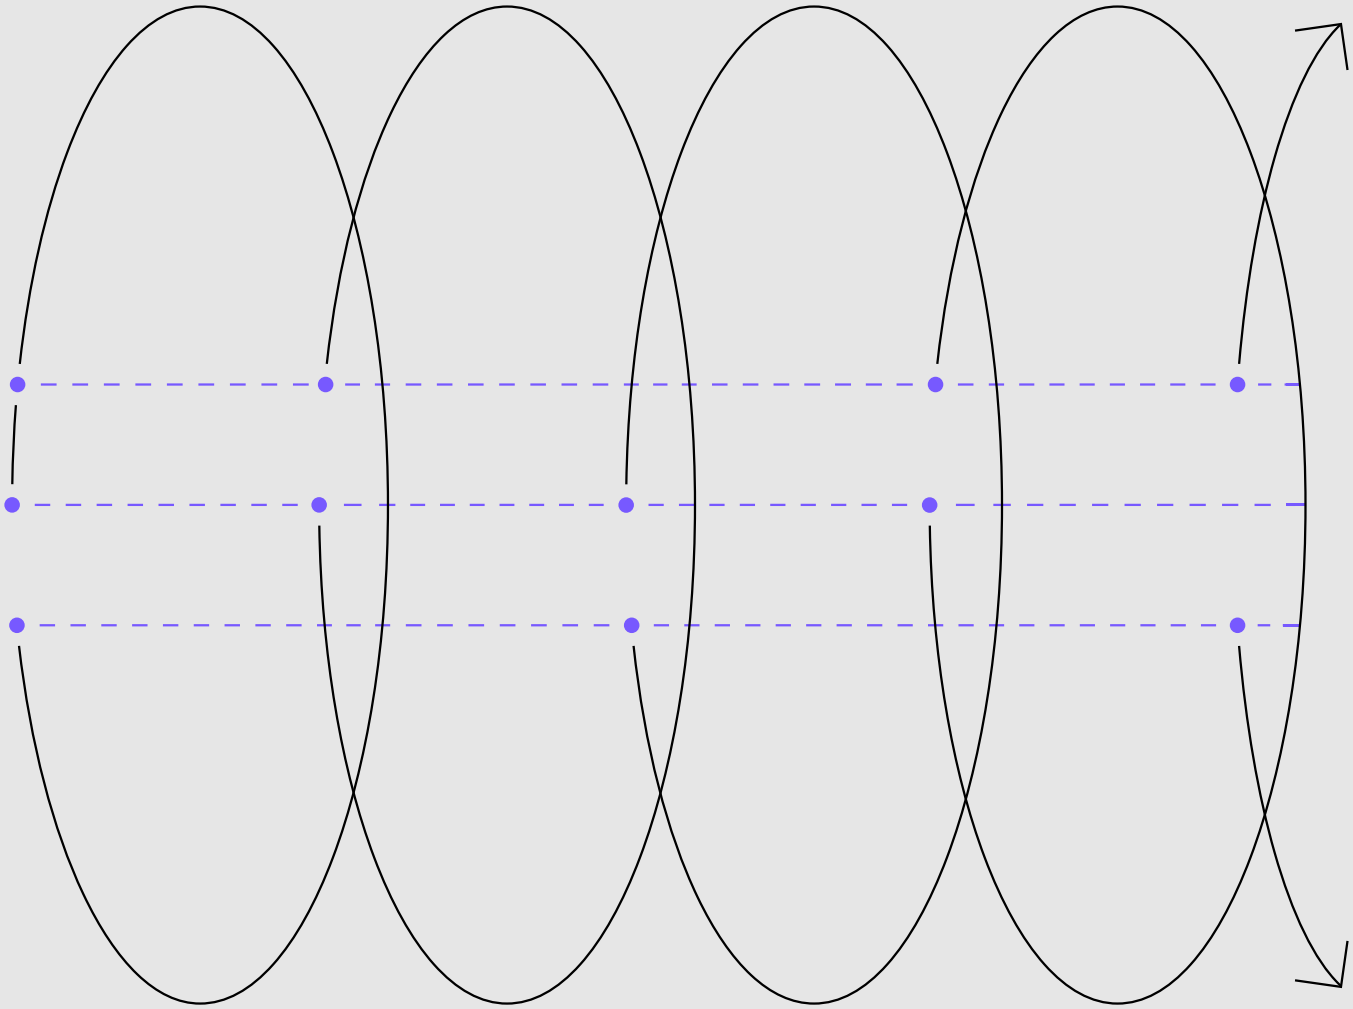
STEM

Домашнее задание

Научная студия. Кадровая динамика

08

Классификация



Домашняя работа. Неделя 8

ЧАСТЬ 1

Возьми предобработанную ранее таблицу. Необходимо исследовать влияние выбора алгоритма, масштабирования и балансировки классов на качество предсказания увольнений. При желании можешь заменить алгоритм на свой из той же категории.

Подготовка

A. Раздели данные по годам: 2022 — обучение, 2023 — тест.
B. Подготовь целевую переменную (`is_out_next_year`) и признаки.
C. В зависимости от алгоритма, используй либо масштабированные данные, либо нет.

> Помни: масштабирование учим на train, применяем к train и test.

Исследование простых алгоритмов

Для каждого алгоритма:

- обучи модель, сделай предсказания на тесте, оцени accuracy, balanced accuracy;
- где уместно, исследуй влияние гиперпараметров;
- для алгоритмов, поддерживающих анализ важности признаков, выведи топ-5.

Алгоритмы:

- KNN;
- дерево решений;
- логистическая регрессия;
- SVM.

Исследование ансамблевых алгоритмов

Для каждого ансамблевого алгоритма:

- обучи модель, сделай предсказания на тесте, оцени accuracy, balanced accuracy;
- где уместно, исследуй влияние гиперпараметров;
- для алгоритмов, поддерживающих анализ важности признаков, выведи топ-5.

Ансамблевые алгоритмы:

- Random Forest;
- бустинг (AdaBoost/XGBoost);
- стекинг.

Балансировка

Для лучшего алгоритма проведи исследование на данных:

- без балансировки;
- `class_weight = 'balanced'`;

- SMOTE (только на train).

Сравни результаты. Что дало наибольший эффект?

Составление сводной таблицы

Составь сводную таблицу (алгоритм, масштабирование, балансировка, accuracy, топ-5 признаков). Ответь на вопросы:

- Какой алгоритм сработал лучше и почему?
- Для каких алгоритмов масштабирование критично? Какой метод лучше?
- Помогает ли балансировка? `class_weight` vs SMOTE?
- Какие признаки оказались важными?

Формат сдачи

Загрузи Python Notebook в LMS с комментариями к каждому этапу решения.

ЧАСТЬ 2

Тебе нужно подготовить часть статьи, посвящённую предобработке данных.

На основе выполненных домашних работ недели 4, 5 и 7, составь главу в статье, посвящённую данным и их подготовке: откуда они, что из себя представляют, какие манипуляции ты с ними проводил для дальнейшего использования их в машинном обучении.

Примеры можно посмотреть в статьях, представленных в LMS в разделе «Командное задание: обзор научной статьи».

Формат сдачи

Часть статьи должна быть представлена в формате Word (.doc/.docx) или PDF.