ПОСОБИЕ ДЛЯ ЗАЩИТЫ · ДВИЖУХА В КАДРАХ

СППР «Кадровая динамика» Как устроен проект

Подробное объяснение данных, модели и приложения. Проверено по текущим файлам на 10.11.2026.

Главная идея. Мы объединяем кадровые данные за 2022-2024 годы, описываем состав и фактическую мобильность сотрудников и оцениваем риск отсутствия человека в следующем годовом срезе. Результат помогает выбрать, какие группы стоит изучить подробнее.

Паспорт проекта	Что имеется сейчас
Данные	52 723 наблюдения сотрудник-год; 22 484 человека; 266 школ; 5 округов за весь период
Текущая модель	CatBoost, бинарный исход, 18 признаков; прогноз для 17 933 строк 2024
Качество на 2023	ROC-AUC 0,7233; AP 0,2967; Brier 0,1054
Приложение	Dash: состав, фактическая мобильность, бинарный прогноз, фильтры и CSV

Как читать по плану защиты

Вопрос защиты	Страницы
1. Как работали с данными и подготовили их?	2-6: поток, источники, очистка, признаки
2. Какие модели рассматривали и что выбрали?	7-8: схема проверки, сравнение и CatBoost
3. Какие метрики получили и что они означают?	9-11: качество, пороги, калибровка
4. Какие признаки оказались значимыми?	12: важности и границы интерпретации
5. Что пробовали и что улучшать?	14: эксперименты и приоритеты
Как показать и воспроизвести проект?	13: интерфейс; 15-16: речь, запуск, источники

Область выводов. Сейчас в выборке есть разные педагогические и административные должности. Отбор только школьных учителей и пересмотр специализаций отложены. Мы не представляем текущие результаты как исследование исключительно школьных учителей или полного реестра Москвы.

1 · ДАННЫЕ И ПОДГОТОВКА

Весь проект: от Excel до экрана

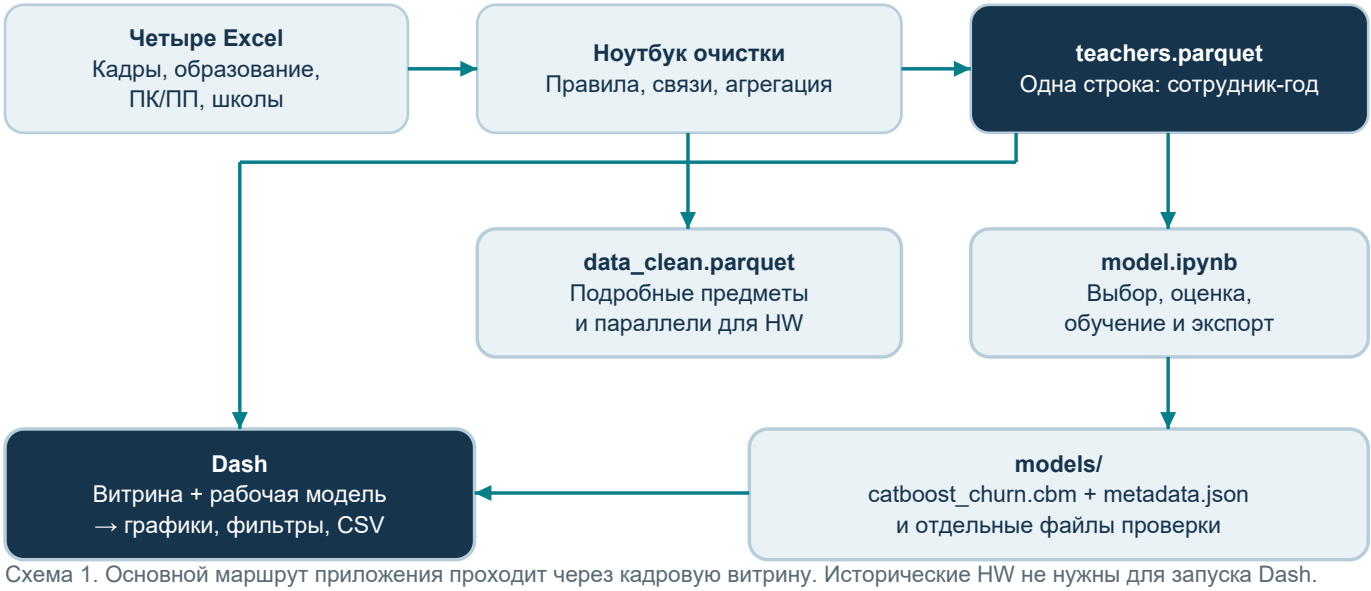


Схема 1. Основной маршрут приложения проходит через кадровую витрину. Исторические HW не нужны для запуска Dash.

Узел проекта	Содержание и ответственность
data/	Четыре исходных Excel и готовая teachers.parquet. Исходные Excel остаются неизменными.
notebooks/	Два рабочих ноутбука: «Предобработка и очистка.ipynb» и model.ipynb. В первом создаются признаки, во втором выбирается и обучается модель.
dashboard/app.py	Собирает интерфейс и callbacks: реакции на вкладки, фильтры, роль и выгрузку.
dashboard/data.py	Читает витрину, модель и JSON; проверяет совместимость; вызывает predict_proba. Обучения и подготовки признаков здесь нет.
filters.py / metrics.py / charts.py	Отбор строк / расчёты показателей и CSV / построение графиков Plotly. components.py содержит общие элементы интерфейса.
dashboard/tabs/ и assets/	Пять вкладок и их компоновка; CSS задаёт внешний вид. tests/ проверяет расчёты, загрузку модели и рендер.
models/	Рабочая и оценочная модели, метаданные, прогноз для сверки, таблицы выбора и порогов.
HW/ и docs/	Исторические задания и результаты; локальная документация и архив прежних версий.
Корень	README.md - контракт и запуск; requirements.txt - зависимости; pytest.ini - настройки тестов; .gitignore - исключения.

Почему два parquet? Подробная таблица хранит записи предметов и параллелей. Кадровая таблица содержит одну строку на сотрудника в год: так один человек не получает больший вес только потому, что ведёт больше предметов.

1 · ДАННЫЕ И ПОДГОТОВКА

Какие данные и что считаем исходом

Источник	Единица исходной записи и использование
Педагоги.xlsx	Листы 2022/2023/2024. Кадровые поля, должность, направление, предмет, параллель. У одного человека много строк из-за учебной нагрузки.
Образование.xlsx	Листы по годам; у человека может быть несколько дипломов и программ ДПО. Даёт признаки образования и часть истории обучения.
ПК-ПП.xlsx	Курсы повышения квалификации и переподготовки по годам; программа, вид и часы.
Школы.xlsx	Справочник школ, округ, здания, контингент. Контингент представлен одним срезом, поэтому это не ежегодная динамика учеников.

Граница выборки и ключ

В кадровых записях оставляются школы из предоставленного справочника. Затем ключ **id + year** становится уникальным. Во всех годах вместе 22 484 человека и 266 школ. Эти данные описывают предоставленный набор, а не доказанно полный состав системы образования города.

Год среза	Всего	Та же школа	Другая школа	Нет в следующем срезе
2022	17 396	14 189	611	2 596 (14,92%)
2023	17 394	14 504	591	2 299 (13,22%)
2024	17 933	Неизвестно	Неизвестно	Неизвестно

Как формируется разметка

Для сотрудника из года Y ищем его id в году Y+1. Есть в той же школе - **mobility_status=0**; есть в другой школе - **1**; нигде в следующем срезе нет - **2**. Бинарная цель **target=1** соответствует только последнему варианту. Переход школы имеет target=0.

Пример. Сотрудник есть в школе A в 2022 и школе B в 2023: это переход, target 2022 = 0. Если в 2023 его нет, target 2022 = 1. Если он вернулся в 2024, исход 2022 всё равно остаётся 1: цель описывает именно следующий срез.

У 344 сотрудников с target=1 за 2022 снова есть запись в 2024. Поэтому «уход» здесь - техническое сокращение для отсутствия в следующем срезе, а не установленное окончательное увольнение. Для 2024 нужен следующий срез, которого в проекте нет: исход сохраняется NaN, а не нулём.

1 · ДАННЫЕ И ПОДГОТОВКА

Как очищаются данные и почему

Шаг	Реализованное правило	Обоснование и предел
Единая схема	Читаем листы годов, добавляем year, переименовываем поля, объединяем записи.	Одинаковые названия позволяют сравнивать годы и связывать источники.
Категории	Должность, степень и категория нормализуются по ключевым словам. Классное руководство: Да/Нет → 1/0.	Сокращаем варианты записи. Классификация должности пока широкая: категория «учитель» включает и другие педагогические позиции.
Текстовые пропуски	Сохраняем явные категории «не указано» / «не_найдено». Для образования отдельно запоминаем, была ли информация.	Отсутствие текста нельзя автоматически считать реальной квалификацией или специализацией.
Повторы	В образовании и курсах удаляются полные технические дубли. Разные программы остаются.	Не завышаем часы и число программ; записи предметов и параллелей в кадровом источнике не считаем ошибкой.
Стаж	Очищенный стаж ограничивается сверху max(возраст - 14, 0). Если педагогический больше общего, три очищенных стажа становятся NaN.	Это явное приближённое правило, а не восстановленный истинный стаж. У 119 пар сотрудник-год исход противоречив: строки сохранены, experience_valid=False.
Даты категории	Невозможные даты выявляются по возрасту и году. Для описательного анализа используются медианы в группах; крайний срок категории ограничен по IQR внутри года.	Даты категории не входят в 18 признаков модели. Эти описательные поправки не используются для оценки её качества.
Даты образования	Сначала сохраняется date_known. Неизвестные даты могут заполняться для отчёта; невозможные даты помечаются.	Выдуманная или подтверждённо ошибочная дата не становится событием недавнего ПК.
Выбросы	Диагностика IQR. Для исследовательского графика часов есть ограничение p99.	Редкое значение само по себе не ошибка. В pk_hours_3y идут полные часы; показатель исключён из модели.

Проверки перед сохранением

Проверяются уникальность id/year, отсутствие конфликтов кадровых полей внутри ключа, наличие округа, согласованность target и мобильности, неизвестность исходов 2024 и корректность стажа. Из подробной таблицы 417 149 × 32 получается кадровая 52 723 × 36.

Принцип: сохраняем исходные значения и создаём очищенные поля. Неизвестный стаж не подменяем нулём, ошибочные даты не выдаём за факты, подозрительные наблюдения не удаляем ради улучшения метрики.

1 · ДАННЫЕ И ПОДГОТОВКА

Как строятся сводные показатели

Сначала из кадровых строк получается база сотрудник-год. Затем к ней добавляются отдельные агрегаты по тому же ключу. Это предотвращает размножение людей при соединении нескольких дипломов, курсов и предметов.

Блок	Расчёт и значение
Нагрузка	n_subjects - число уникальных предметов; n_parallels - число параллелей; min/max_parallel - младшая/старшая параллель. n_subject_parallel - число уникальных пар предмет × параллель.
Образование	edu_higher=1, если есть высшее образование/аспирантура. edu_pedagogical=1 при высшем образовании и педагогических словах в вузе, специализации или квалификации. Это текстовая эвристика.
Соответствие профиля	edu_speciality_match сравнивает основы слов направления и образования с простым словарём синонимов. Для неучителей/неизвестного направления NaN. В модель этот показатель не входит.
Переподготовка	retraining=1 при записи ПП в ПК-ПП либо ДПО со специализацией/квалификацией. Короткие программы по ключевым словам отдельно исключаются из такого признака.
Недавнее ПК	pk_recent=1 при известном допустимом событии обучения в окне [Y-2; Y]. Учитываются сведения, которые появились в выгрузке не позднее Y.
Запись текущего года	pk_this_year=1 при наличии строки в листе ПК-ПП года Y. Это признак записи ПК/ПП, а не доказанная оценка качества курса.
Часы	pk_hours_3y - сумма доступных часов в окне [Y-2; Y]. Реально есть один год истории для 2022, два для 2023 и три для 2024: прямое сравнение ограничено.

Защита от информации из будущего

У события различаются **год прохождения** и **год появления в источнике**. Например, диплом с датой 2021, впервые появившийся в выгрузке 2024, нельзя использовать для признака 2022. Поэтому одновременно проверяются source_year ≤ Y и дата события в окне [Y-2; Y].

Школьный контекст

Число сотрудников школы берётся из текущего года, контингент - из единственного справочного среза. Отношение ≤60 учеников на сотрудника используется как **эвристика условной полноты выгрузки**. При большем отношении students_per_teacher скрывается. Это не норматив нагрузки и не подтверждение полного штата.

Что означает 0 в признаках образования/ПК? В предоставленных записях не найдено подтверждения по принятому правилу. Ноль не доказывает, что человек никогда не получал образование или не проходил курсы.

1 · ДАННЫЕ И ПОДГОТОВКА

Что хранит витрина и что видит модель

В кадровой витрине **36 столбцов**. Из них модель использует **18**: первые три группы ниже. Четыре строковые категории CatBoost обрабатывает нативно; остальные 14 признаков числовые или бинарные.

Назначение	Имена полей
В модели: возраст, стаж (3)	age; experience_age_pedagogic_clean; experience_age_other_clean
В модели: нагрузка и флаги (11)	n_subjects; n_parallels; min_parallel; max_parallel; sex; class_manager; edu_higher; edu_pedagogical; pk_recent; pk_this_year; retraining
В модели: категории (4)	main_position_cat; academic_degree_cat; category_qual_cat; district
Идентификация и отображение (4)	id; year; school_num; age_group
Дополнительные поля (5)	experience_age_all_clean; experience_valid; category_due_clean; speciality; edu_speciality_match
Школьные показатели (5)	n_subject_parallel; school_teachers; school_students; students_per_teacher; school_staff_complete
Профразвитие вне модели (1)	pk_hours_3y
Известные исходы (3)	mobility_status; movement_type; target

Почему часть полей исключена

Поле/группа	Причина
speciality и edu_speciality_match	В 2022 направление неизвестно у 97,06%, в 2023 - у 10,04%, в 2024 - у 9,75%. Такой сдвиг заполненности делает перенос модели ненадёжным. Направление также не равно полному списку предметов.
pk_hours_3y	Неравная глубина доступной истории: год, два, три. Модель могла бы улавливать структуру выгрузки.
id / school_num / year	Идентификаторы и сам год не используются как предикторы. district сохранён как категориальный контекст.
target, mobility_status, movement_type	Это ответы, которые мы хотим предсказать. Их попадание в X было бы прямой утечкой.

Пропуски: CatBoost принимает числовые NaN. В логистической регрессии, дереве и случайном лесе сравнения медианы вычисляются только на обучающей части. У логистической регрессии там же обучается StandardScaler; категории кодируются OneHotEncoder с обработкой неизвестных значений.

Список speciality в интерфейсе пока отражает направление исходной записи. Он не является очищенной предметной классификацией школьных учителей. Этот вопрос отложен; сами поля в рамках последних исправлений не менялись.

2 · ВЫБОР МОДЕЛИ

Как разделены подбор, оценка и прогноз



Схема 2. Один выбранный алгоритм и рецепт обучения, два сохранённых экземпляра для разных задач. Это не ансамбль из двух моделей.

Порядок, который выполняет model.ipynb

1. Внутри 2022 создаются три одинаковых для всех кандидатов стратифицированных фолда. Каждый сотрудник этого года находится в одном проверочном фолде. Модель обучается на остальных двух; прогнозы объединяются в OOF - прогнозы для строк, на которых конкретный экземпляр не обучался.

2. На OOF сравниваются алгоритмы и восемь настроек CatBoost. Сначала допускаются варианты с Brier лучше постоянного прогноза; затем выбирается максимальный AP. Это практическое правило выбора, а не доказательство идеальной калибровки.

3. По OOF выбранной модели выбирается порог: максимальная precision среди вариантов с recall ≥70%. Ориентир 70% - заданная цель охвата, а не измеренный экономический оптимум.

4. Рецепт фиксируется. Оценочная модель обучается на всём 2022 и выдаёт вероятности для 2023. Год 2023 не передаётся в fit/eval_set, по нему в этом запуске не меняются параметры и число деревьев.

5. После оценки тот же рецепт обучается на 2022+2023 для прогноза по срезу 2024. Эти новые вероятности нельзя проверить по отсутствующим исходам 2024.

Ограничение независимости: 2023 уже изучался в прежних экспериментах, поэтому это ретроспективная временная проверка. Нынешняя процедура аккуратнее, но год не становится заново нетронутым тестом.

Те же люди могут встречаться в соседних годах: это соответствует задаче прогнозирования действующих сотрудников на следующий год. Проверка не доказывает перенос на новые школы, другой регион или другие периоды. Случайные фолды внутри 2022 также не проверяют такой перенос.

2 · ВЫБОР МОДЕЛИ

Что сравнили и почему выбран CatBoost

Текущая процедура сравнивает простой ориентир и четыре семейства обучаемых моделей на одинаковых OOF-разбиениях 2022. CatBoost строит последовательность деревьев, исправляющих ошибки предыдущих; умеет работать с категориями и нелинейными связями.

Кандидат на OOF 2022	AP ↑	ROC-AUC ↑	Brier ↓
Постоянная доля	0,1492	0,4998	0,1270
Логистическая регрессия	0,2995	0,6924	0,1180
Дерево с весами	0,2831	0,6783	0,2153
Случайный лес	0,3203	0,7164	0,1158
CatBoost: глубина 4, 150 деревьев, без весов	0,3204	0,7153	0,1159
CatBoost: глубина 4, 300, без весов	**0,3266**	**0,7173**	**0,1155**
CatBoost: глубина 6, 150, без весов	0,3233	0,7171	0,1157
CatBoost: глубина 6, 300, без весов	0,3266	0,7159	0,1156

Глубины 4 и 6 с 300 деревьями почти равны по AP; разница до округления около 0,000002. Текущий код выбирает точный максимум - глубину 4. Это не доказательство значимого превосходства. Разрыв с лесом также небольшой.

Небольшая сетка вместо сложного поиска

Полная сетка: глубина **4/6** × деревья **150/300** × веса **None/Balanced** = 8 комбинаций. Общие настройки: learning_rate=0,06; l2_leaf_reg=5; border_count=64; Bernoulli bootstrap; subsample=0,8; rsm=0,8; random_seed=42. Ранней остановки нет: число деревьев выбирается внутри 2022.

Сетка небольшая, понятная и воспроизводимая. Optuna сама по себе допустима; методологию определяют разбиение данных, критерий и доступ к тесту. Текущая сетка достаточна для учебного сравнения, но не доказывает глобально оптимальные параметры.

Что было в HW8

Исторически изучались KNN, дерево, логистическая регрессия, SVM, случайный лес, AdaBoost и stacking; Standard/RobustScaler, веса классов и SMOTE. На 2023 многие варианты дали accuracy около 0,868 и balanced accuracy около 0,50. Постоянный ответ «не ушёл» уже даёт accuracy 0,8678. Поэтому высокая accuracy почти не говорила о поиске уходов.

У дерева с весами HW8 balanced accuracy на 2023 составила 0,6041. Нельзя напрямую сравнивать её с ROC-AUC или AP текущего CatBoost: различаются метрика, набор признаков и правило классификации. Исторические работы сохранены отдельно.

Чем отличаются рассмотренные алгоритмы

Логистическая регрессия складывает взвешенные признаки и переводит результат в вероятность. **Дерево** строит последовательность условий; **случайный лес** усредняет множество деревьев. **KNN** ориентируется на похожих соседей, **SVM** ищет разделяющую границу. **AdaBoost** последовательно усиливает слабые деревья. **Stacking** учит итоговую модель объединять ответы базовых моделей.

Параметры CatBoost: глубина задаёт сложность дерева, число деревьев - длину последовательности, learning_rate - величину шага, l2 - регуляризацию. Subsample/rsm задают долю строк/признаков, border_count - число границ числовых признаков. Веса повышают влияние редкого класса при обучении; в текущем рецепте они отключены.

3 · МЕТРИКИ И РЕЗУЛЬТАТЫ

Какое качество показала временная проверка

Далее все метрики относятся к **evaluation_2023.cbm**: обучение только на 2022, проверка на 17 394 наблюдениях 2023. Положительных исходов 2 299, или 13,22%.

Метрика	CatBoost	Постоянный прогноз	Смысл
ROC-AUC ↑	0,7233	0,5000	Способность ранжировать два класса
AP ↑	0,2967	0,1322	Сводная precision по уровням recall
Brier ↓	0,1054	0,1150	Средний квадрат ошибки вероятности
Logloss ↓	0,3542	0,3917	Вероятностная ошибка с сильным штрафом за уверенные ошибки

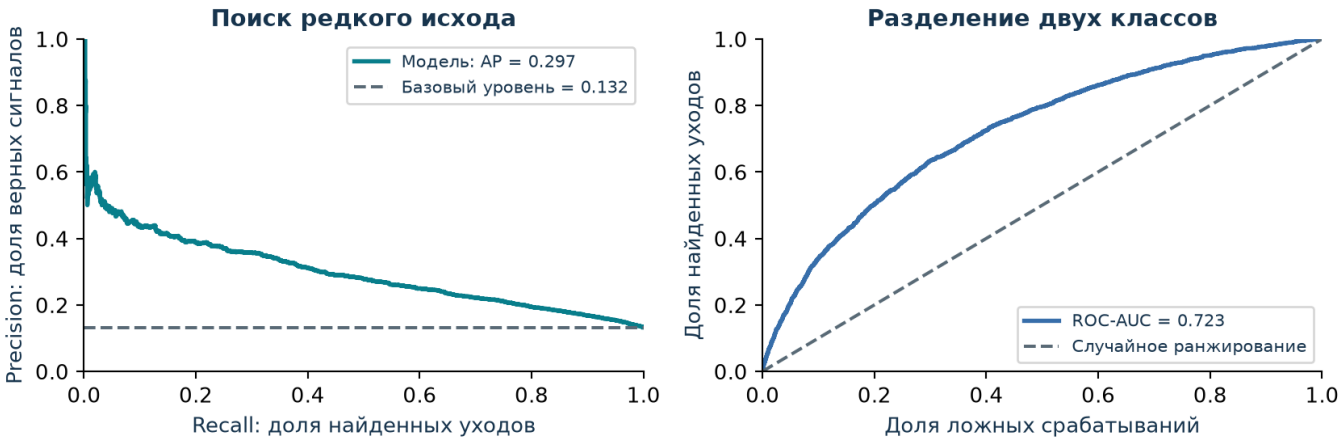


График 1. Слева precision падает при расширении списка риска; справа ROC-кривая выше случайной диагонали. AP в проекте считается average_precision_score, а не трапецеидальной площадью PR-кривой.

Как объяснить без специальных терминов

ROC-AUC 0,7233: при случайном выборе одного отсутствующего и одного присутствующего сотрудника модель примерно в 72% таких пар поставит отсутствующего выше по риску. Это **не 72% правильных персональных прогнозов**.

AP 0,2967: суммарное качество поиска редкого исхода заметно выше базовых 0,1322. AP нельзя трактовать как одну неизменную precision для любого порога. Конкретные списки нужно оценивать отдельно.

Brier и logloss: модельные вероятности полезнее постоянной доли. Базовый прогноз здесь равен доле уходов обучающего 2022, а не подогнанной по 2023 величине. Улучшение Brier около 8,4% относительно этого ориентира.

Оценка результата: умеренный и содержательный результат для учебной СППР. Модель помогает расставить приоритеты для анализа. Точность автоматического кадрового решения этими числами не подтверждена.

3 · МЕТРИКИ И РЕЗУЛЬТАТЫ

Почему разные пороги дают разные ответы

Вероятность превращается в сигнал при p ≥ порога. Низкий порог находит больше уходов и создаёт больше ложных сигналов. **Precision** отвечает «какая доля сигналов верна?», **recall** - «какую долю всех уходов нашли?».

Правило на 2023	Сигналов	Precision	Recall	F1
Порог OOF 2022: 0,1320	7 596	21,79%	71,99%	0,3345
Граница Dash: 0,25	2 398	33,53%	34,97%	0,3423
Граница Dash: 0,50	216	48,15%	4,52%	0,0827

Что происходит при экспериментальном пороге 0,1320



График 2. Матрица ошибок на 2023: 1 655 верных сигналов риска, 5 941 ложный сигнал, 644 пропущенных ухода и 9 154 верных отсутствия сигнала.

Чтобы найти около 72% отсутствующих, приходится включить в список **43,7% сотрудников**. Из каждых 100 сигналов примерно 22 окажутся верными, 78 - ложными. Такой список подходит для дополнительного анализа, но может быть слишком большим для индивидуальной работы.

Пороги интерфейса - отдельная шкала

В Dash сохранены три уровня: низкий p <0,25; средний 0,25≤p<0,50; высокий p≥0,50. Это принятые границы отображения. Они не выбраны по стоимости ошибки и не гарантируют охват 70% уходов.

При пороге 0,50 модель на проверке нашла только 4,52% уходов. Называть этот список полным перечнем будущих уходов нельзя. Выбор рабочего порога требует договориться, сколько сотрудников команда способна проверить и насколько дороги пропуски и ложные сигналы.

3 · МЕТРИКИ И РЕЗУЛЬТАТЫ

Вероятности, список внимания и устойчивость

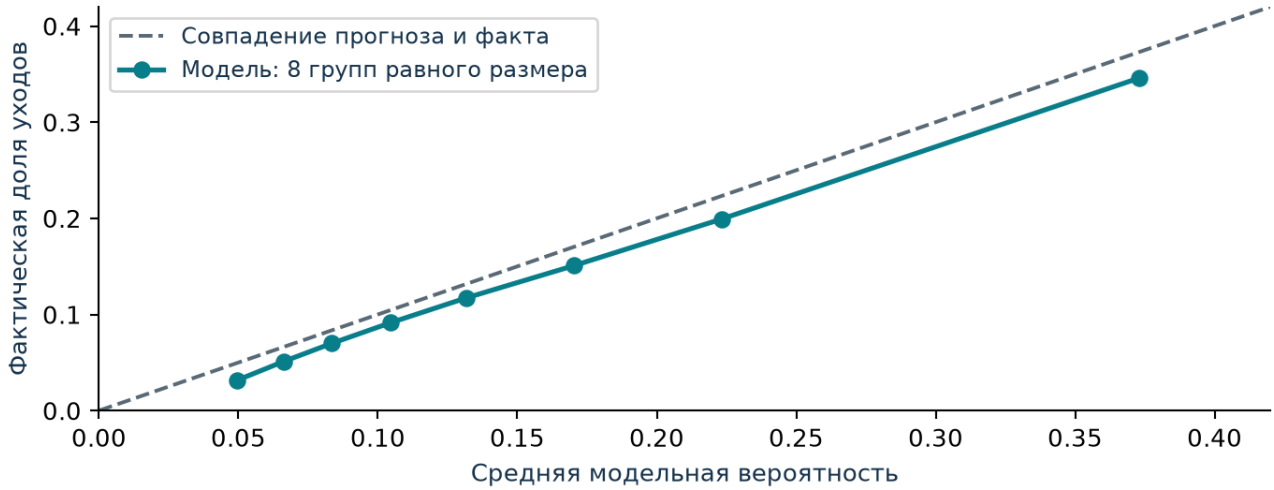


График 3. Каждая точка - примерно восьмая часть сотрудников 2023. Ниже диагонали означает, что модель в среднем завышает вероятность в этой группе.

Средний прогноз составляет **15,03%**, фактическая доля - **13,22%**: завышение около 1,81 процентного пункта. В самой рискованной восьмой части средний прогноз 37,28%, фактическая доля 34,57%. По графику вероятности разумны, но не идеально откалиброваны. На 2023 калибровка проверяется без донастройки.

Если ресурс ограничен: смотрим верхнюю часть рейтинга

Выбранная группа 2023	Человек	Доля уходов	Охват всех уходов	Выше общей доли
10% с максимальным риском	1 740	35,86%	27,14%	в 2,71 раза
20% с максимальным риском	3 479	29,20%	44,19%	в 2,21 раза

Простое объяснение: среди 100 человек в верхней десятой части примерно 36 отсутствуют в следующем срезе; в случайной сотне - около 13. Это показывает пользу ранжирования, хотя большинство в верхней группе всё равно остаётся.

Что проверили на разных разбиениях 2022

Seed разделения 80/20	AP	ROC-AUC	Brier
42	0,3117	0,7141	0,1165
17	0,3424	0,7293	0,1142
123	0,3469	0,7257	0,1142

Это диагностические повторения для выбранного рецепта. Они показывают зависимость от разбиения, но не являются доверительным интервалом и не заменяют проверку на другом году. Есть только один итоговый временной переход 2022 → 2023; для 2024 истинное качество пока неизвестно.

Средняя вероятность, частота фактических исходов и доля высокого риска - три разных показателя. Их нельзя взаимозаменять в карточках и устном объяснении.

4 · ИНТЕРПРЕТАЦИЯ

Какие признаки важны и что это означает

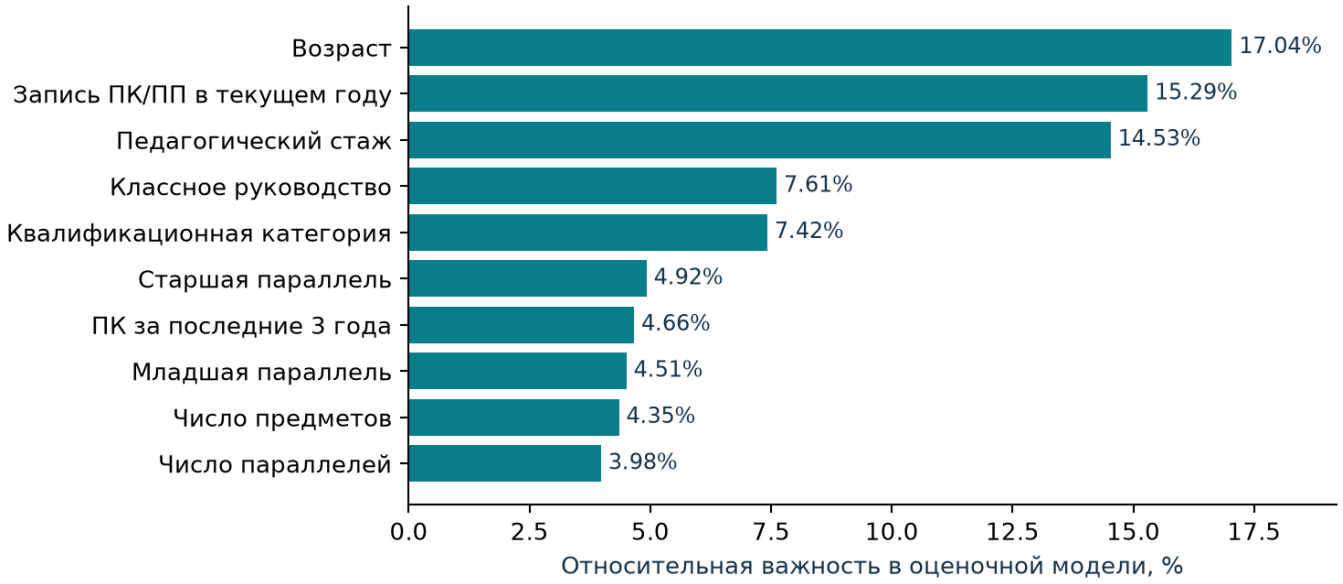


График 4. Десять наиболее важных признаков оценочного CatBoost. Метод - встроенная PredictionValuesChange; нормировка по всем 18 признакам до 100%. Это не SHAP.

Что можно сказать по результату

Наибольший вклад в изменение предсказаний дают **возраст (17,04%)**, **запись ПК/ПП текущего года (15,29%)**, **педагогический стаж (14,53%)**, **классное руководство (7,61%)** и **квалификационная категория (7,42%)**. Модель использует демографический контекст, профессиональный статус и сведения об активности.

Эти проценты описывают относительную роль признака в работе модели. Они не означают, что «17% увольнений вызваны возрастом». Важность также не показывает направление: из одного столбика нельзя заключить, что более высокий стаж обязательно повышает риск.

Почему осторожность особенно нужна с курсами

Связь записи ПК/ПП с исходом может отражать различия должностей, полноту выгрузки, доступность обучения и другие факторы. Модель не доказывает, что отправка на курсы снизит риск. Обратная ситуация также возможна: особенности занятости влияют и на обучение, и на присутствие в следующем срезе.

Формулировка для защиты: «Важности помогают понять, какие сведения использует модель. Это статистические связи в предоставленных данных. Причины ухода и эффект кадровых мер мы отдельно не оценивали».

Возраст и стаж связаны между собой; их индивидуальные важности могут перераспределяться. «Значимый» здесь означает важный для предсказания, а не статистическую значимость с p-value. Для понимания направления связей можно дальше добавить PDP/SHAP с пояснением ограничений; полноценного SHAP-контура в текущем приложении нет.

ПРИЛОЖЕНИЕ · ПРИМЕНЕНИЕ РЕЗУЛЬТАТА

Что работает в Dash и как читать экран

Вкладка	Реализовано и как интерпретировать
Обзор	Состав и территориальные показатели. При наличии прогноза за 2024 плитки округов показывают долю высокого риска. Для прошлых лет используется фактический отток; переход школы и отсутствие в системе могут объединяться в показатель оттока.
Кадровый состав	Возраст, стаж, категории, образование и профразвитие; сравнение выбранной группы с городским уровнем. Отклонение от среднего не является оценкой качества школы.
Мобильность	Три фактических исхода за годы, для которых известен следующий срез. При выборе 2024 используется последний доступный известный исход 2023 с указанием года.
Прогноз	Бинарная вероятность отсутствия в следующем срезе для 2024; средние вероятности и группы риска. 1-р означает присутствие в системе, включая смену школы.
What-if	Вкладка с пояснением. Пересчёт вероятности по изменённым параметрам и эффект мероприятий не реализованы.

Роли и фильтры

Доступны демонстрационные роли города, округа и директора. Роль выбирается вручную, это не авторизация. Фильтры: год, округ, школа, должность, направление, пол, возраст, стаж, категория, степень, образование, ПК, переподготовка, классное руководство и условная полнота выгрузки.

Дополнительные фильтры применяются к сравнению школы и города одинаково. По умолчанию включён фильтр условно полных выгрузок; выбранная школа из него не исключается. Поэтому числа интерфейса могут отличаться от всей витрины. Неизвестный стаж сохраняется при полном диапазоне; при ограничении диапазона остаются только известные значения внутри него.

Защита от неверных выводов и выгрузка

Рейтинги риска показывают группы от пяти человек после фильтров и численность N. Медианы стажа считаются по известным значениям. CSV содержит snapshot_year, mobility_year, teachers, mobility_teachers и experience_known_n: у текущего состава и исторической мобильности могут быть разные годы и знаменатели. Кодировка UTF-8 BOM; пустая выгрузка сохраняет заголовки.

Что выдала рабочая модель для 2024

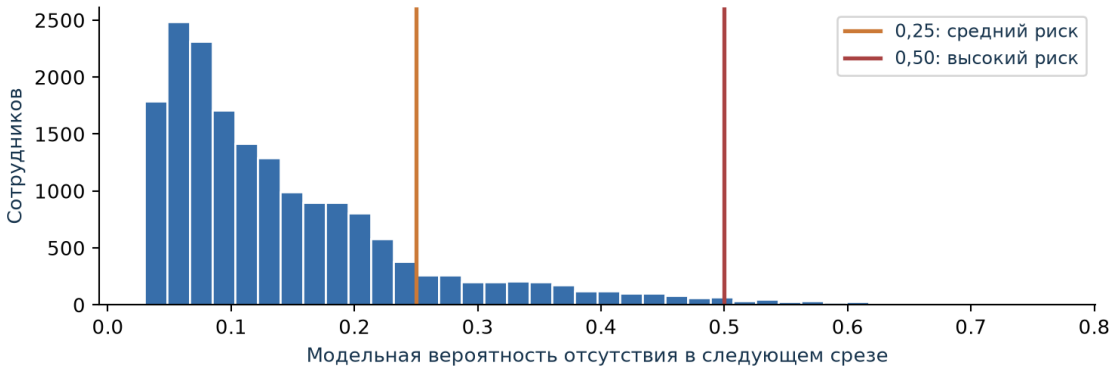


График 5. Исходы неизвестны. Среди 17 933 сотрудников высокий риск у 238, средний у 2 135, низкий у 15 560. Средняя вероятность 14,51%. При фильтре условно полных выгрузок высокий риск у 233 человек. Это модельные группы, не фактические уходы.

Проверки: 133 теста, 600 комбинаций рендера, четыре HTTP-ответа 200. Все 17 933 вероятности совпали с прямым вызовом и сохранённым файлом. Это проверка кода, а не доказательство качества прогноза. Клики в браузере и чистая установка на другом ПК не проверялись.

5 · ЭКСПЕРИМЕНТЫ И РАЗВИТИЕ

Что не помогло и что улучшать дальше

Что пробовали	Что получилось и решение
Balanced в текущем CatBoost	Все четыре варианта дают OOF Brier 0,1985-0,2120 против 0,1270 у постоянного прогноза. Средняя вероятность 42-45% при доле исхода около 15%. В текущем виде эти вероятности не подходят; выбрано обучение без весов.
Более глубокие деревья	Глубина 6 не дала убедительного выигрыша AP относительно 4. Оставлена простая глубина 4; статистическое превосходство не доказано.
Масштабирование, SVM, KNN и stacking в HW8	Высокая accuracy часто сопровождалась balanced accuracy около 0,50. Усложнение само по себе не решило поиск редкого класса. Масштабирование по-прежнему уместно для линейной модели сравнения.
SMOTE и веса в HW8	Некоторые варианты улучшили balanced accuracy: дерево с весами достигло 0,6041 на 2023. Это полезный опыт, а не доказательство бесполезности балансировки. SMOTE после one-hot может создавать дробные синтетические категории.
Optuna в прежнем контуре	Заменена небольшой прозрачной сеткой в рабочем ноутбуке. Проблема качества не сводится к библиотеке поиска; важнее временная проверка, признаки и критерий выбора.
Стаж с противоречием и ошибочные даты	Вместо нулевого «прочего» стажа конфликтные пары стали неизвестными. Ошибочная/выдуманная дата не создаёт событие ПК. После исправлений модель оценена заново.

План улучшений по приоритету

1. Уточнить область исследования. Когда вернёмся к отложенному вопросу, выделить школьных учителей и предметные варианты должности, пересмотреть соответствие направления и предметов. Затем повторить весь подбор и проверку. Рост метрики заранее не гарантируется.

2. Проверить ошибки по группам. Рассмотреть ложные сигналы и пропуски по должности, возрасту и школе; проверить доступность признаков на момент прогноза. Срез Y должен быть полностью сформирован: внутри года часть ПК/ПП ещё неизвестна.

3. Согласовать практический список. Выбрать размер верхней группы риска или порог с учётом ресурсов кадровой работы. Если нужны точные вероятности, оценить калибровку внутри обучающей процедуры и проверить её перенос без настройки на итоговом тесте.

4. Усилить подтверждение качества. При появлении следующего среза провести новый временной тест. Для текущих данных оценить неопределённость и качество по школам; отдельно проверить перенос на новые школы, если это станет задачей.

Для сдачи сначала важны корректные данные, честные ограничения и работающий демонстрационный сценарий. Расширение сетки и новые ансамбли имеют меньший приоритет.

ПЯТЬ ОТВЕТОВ · ГОТОВАЯ ОСНОВА ВЫСТУПЛЕНИЯ

Как рассказать проект на защите

1. Как работали с данными?

«Мы объединили четыре источника: кадровые записи, образование, курсы и справочник школ за 2022-2024. В исходнике человек повторялся из-за предметов и параллелей, поэтому сделали отдельную витрину сотрудник-год. Проверили пропуски, повторы, стаж и даты; исходные значения сохранили. Получили 52 723 наблюдения. Уход определили как отсутствие в следующем срезе, а неизвестные исходы 2024 не заполняли».

2. Какие модели рассмотрели и выбрали?

«В учебных работах пробовали семь семейств, масштабирование и балансировку. В рабочем ноутбуке сравнили постоянный прогноз, логистическую регрессию, дерево, лес и восемь настроек CatBoost на одинаковых фолдах 2022. Выбрали CatBoost глубины 4 с 300 деревьями без весов: он показал наибольший AP среди вариантов с Brier лучше базового прогноза. Его преимущество над лесом небольшое».

3. Что показали метрики?

«На временной проверке 2022 → 2023 получили ROC-AUC 0,723 и AP 0,297 против базовых 0,132 по AP. Среди 10% с наибольшим риском фактически отсутствовали 36% против 13% в общей выборке. Это умеренно полезное ранжирование. Порог с охватом около 72% создаёт много ложных сигналов, поэтому модель используем для дополнительного анализа, а не автоматического решения».

4. Какие признаки оказались важны?

«По встроенной важности CatBoost выделяются возраст, запись ПК/ПП в текущем году, педагогический стаж, классное руководство и категория. Это описание того, как работает модель. Оно не доказывает причины ухода, направление связи или то, что отправка на курсы изменит исход».

5. Что не сработало и что дальше?

«Веса классов в текущем CatBoost ухудшили качество вероятностей; более глубокие деревья не дали убедительного выигрыша. Высокая accuracy исторических моделей была малоинформативна при редких уходах. Дальше приоритетны уточнение учительской выборки и предметов, анализ ошибок, выбор рабочего списка по ресурсу и проверка на новом году. Полные What-if и SHAP пока не реализованы».

Сценарий показа на 2-3 минуты

1. Обзор 2024: назвать область и текущие фильтры.
2. Состав: выбрать округ/школу и показать сравнение.
3. Мобильность 2023: объяснить три фактических исхода.
4. Прогноз 2024: показать бинарный риск и пояснить неизвестность результата.
5. Выгрузить CSV: показать годы и знаменатели. Модель и два ключевых графика объяснить по страницам 7-12.

Если спросят про две модели: «Это один выбранный алгоритм. Один экземпляр нужен для оценки без обучения на проверочном годе, второй затем обучен на всех известных годах для применения».

ВОСПРОИЗВОДИМОСТЬ · СЛОВАРЬ · ИСТОЧНИКИ

Как проверить каждое утверждение

Действие	Как воспроизвести
Запуск готового приложения	.\.venv\Scripts\python.exe dashboard/app.py Открыть http://127.0.0.1:8050. Готовые parquet и модель уже нужны; обучение при запуске не выполняется.
Автоматические проверки	.\.venv\Scripts\python.exe -m pytest -q -p no:cacheprovider
Пересборка данных	Ноутбук очистки: Restart and Run All. Для проверки задать временный OUTPUT_DIR: по умолчанию он перезаписывает два parquet.
Повторение модели	model.ipynb: Restart and Run All в окружении проекта. В конце обновляются модели и JSON. После замены витрины/артефактов перезапустить Dash.

Какие файлы являются текущим источником результатов

Файл	Что проверять
notebooks/model.ipynb	Списки признаков, OOF, сетка, порог, временная оценка, графики, важности и экспорт.
models/metadata.json	Точный рецепт, признаки и порядок, годы, версии пакетов, метрики и ограничения оценки.
evaluation_2023.cbm / catboost_churn.cbm	Первый воспроизводит метрики 2023; второй используется Dash для 2024.
model_cv_results.csv / model_thresholds_2023.csv	Числа сравнения на OOF 2022 / результат заранее заданных порогов на 2023.
forecast_2024.parquet	Сохранённые вероятности для сверки. Dash считает их из рабочей модели, этот файл напрямую не читает.
README.md и ноутбук очистки	Контракт 36 полей и точные правила получения витрины.
HW/HW_8_Тестирование_моделей.ipynb	Исторические эксперименты. Accuracy, balanced accuracy, признаки и подготовка отличаются от текущей оценки.

Мини-словарь

СППР - система поддержки принятия решений. **Срез** - данные за конкретный год. **Витрина** - готовая сводная таблица. **Признак** - вход модели; **target** - ответ для обучения. **OOF** - прогноз на строках, исключённых из обучения соответствующего фолда. **Baseline** - простой ориентир. **Precision / recall** - доля верных сигналов / охват исходов. **Калибровка** - соответствие вероятностей фактическим частотам. **NaN** - неизвестное значение.

Документ описывает текущее состояние, а не все обещания исторической спецификации. Требования и макет находятся в docs/; числа макета демонстрационные. Последние технические проверки описаны в AUDIT_FIXES.pdf. Старые artifacts.pkl, catboost_target.cbm и HW7 не являются источниками рабочего прогноза.

Справка по определениям метрик: scikit-learn, разделы «Precision-Recall» и «Probability calibration».
scikit-learn.org: Precision-Recall · scikit-learn.org: Probability calibration